Săptămâna 2 — Sequence Alignment (TP53 RefSeq mRNA) Paul Hondola

Secvențe proprii (Lab 1, NCBI RefSeq): NM_000546.6 (*Homo sapiens*, 2512 nt), NM_011640.3 (*Mus musculus*, 1781 nt), NM_131327.2 (*Danio rerio*, 2233 nt).

Task 1 — Distanțe perechi (*p-distance*, 3p)

Lungimile diferă (1781–2512 nt), deci Hamming nu se aplică; s-a calculat **p-distance** pe aliniamente globale (`PairwiseAligner`, $+1/-1/-2$; nu `globalxx`, ale cărui gap-uri gratuite ocolesc nepotrivirile), fără coloanele cu gap. Biopython alege unul dintre multele aliniamente co-optime, deci toate numărătorile din pagină depind de această alegere (ordinea argumentelor e fixată).

Accesie (Organism)	NM_000546.6	NM_011640.3	NM_131327.2
NM_000546.6 (*Homo sapiens*, 2512 nt)	0.0000	0.1641 (287/1749)	0.3809 (836/2195)
NM_011640.3 (*Mus musculus*, 1781 nt)	—	0.0000	0.3692 (648/1755)
NM_131327.2 (*Danio rerio*, 2233 nt)	—	—	0.0000

Interpretare: Cele mai apropiate sunt omul și șoarecele ($p = 0.1641$, de peste două ori sub ≈ 0.37–0.38 față de peștele zebră), ambele mamifere placentare (divergență ≈ 90 mil. ani, față de ≈ 430 mil. ani pentru teleosteeni). Semnalul fiabil vine din regiunea codantă ($p = 0.171$); $p = 0.078$ pe 3′-UTR e un artefact (737 coloane cu gap eliminate; local: 0.318), iar 5′-UTR are 0.388.

Task 2 — Aliniere pe perechi: Global vs. Local (NM_000546.6 vs. NM_011640.3, 4p)

Cu scor afin ($+2/-1$, gap $-2/-1$), alinierea **locală** atinge scorul **2014.0** (față de **1664.0** la globală), izolând regiunea omoloagă (`0..1790` pe om vs. `22..1775` pe șoarece; 1326 potriviri) și ignorând ≈ 720 nt din 3′-UTR-ul uman; are 193 baze de gap în 96 deschideri (42 în 5′-UTR, 32 în CDS, 119 în 3′-UTR). Constrânsă să alinieze transcripturile cap-coadă (`0..2512` vs. `16..1781`), alinierea **globală** acumulează **839 baze de gap** (168 deschideri; 64/32/**743** pe aceleași regiuni; 16 terminale, 823 interne), pierzând 350 puncte. Pentru a acoperi diferența de lungime din 3′-UTR, global deplasează segmentul murin `1599-1621` cu ≈ 380 nt în aval (`2004-2059`) și îl fragmentează cu 33 baze de gap, pe când local îl păstrează compact (`1599-1651` vs. `1625-1673`):

```
[GLOBAL] NM_000546.6 2004 AGGATTTCATCTCTTGTATATGATGATCTGGATCCACCAAGACTTGTTTTATGCTC 2059
                          |.|| ||| |.|||||             ||     ||    |     |.||
         NM_011640.3 1599 AAGA-TTC-TATCTTG-------------GG-----CC----C-----TCAT---- 1621
[LOCAL]  NM_000546.6 1625 -ACATTCTAGGTAGGGGCCCACTTCACCGTAC-TA---ACCAGGG--AAGCTGTCC 1673
                           |.||||||..| .||||||.|.| |..||.| ||   .||||||  .| ||.|||
         NM_011640.3 1599 AAGATTCTATCT-TGGGCCCTCAT-AGGGTCCATATCCTCCAGGGCCTA-CTTTCC 1651
```

Task 3 — Aliniere multiplă online (EBI MSA, 3p)

MSA online EMBL-EBI (instrument echivalent: MUSCLE 3.8, format Clustal; `data/clustalo_msa.aln`): 2801 coloane, 799 invariante (`*`, 28.53%). Regiunea marcată, coloanele `923..967`:

```
NM_000546.6  CTGCATGGGCGGCATGAACCGGAGGCCCATCCTCACCATCATCAC  865-909
NM_011640.3  CTGCATGGGGGGCATGAACCGCCGACCTATCCTTACCATCATCAC  871-915
NM_131327.2  CTGCATGGGGGGGATGAACCGCAGGCCCATCCTCACAATCATCAC  798-842
             ********* ** ********  * ** ***** ** ********
```

Motiv conservat și rolul MSA: Fereastra (82.2% identitate, cu motivul contiguu de 9 nt `CTGCATGGG`) codifică `Cys242-Thr256` (`CMGGMNRRPILTIIT`), identice la toate speciile, de la bucla L3 (rez. ≈ 237–250) a domeniului de legare la ADN. Selecția purificatoare se explică prin rolul lor: `Cys242` coordonează Zn^{2+}, `Arg248` contactează șanțul minor, iar `Gly245`/`Arg249` stabilizează structural bucla. Cele 8 substituții sunt sinonime (7 la baza a 3-a; `Arg249`: `AGG`→`CGA` schimbă și baza 1). MSA ajută când comparăm o familie: toate speciile stau în aceleași coloane, deci situsurile constrânse se văd direct, ceea ce perechile independente nu garantează.

Bonus — Aliniere semiglobală (+1p)

`PairwiseAligner(mode="global", end_gap_score=0)` urcă scorul de la 1664.0 la **2014.0**, egal cu cel local. Alinierea (om `0..1980`, șoarece `22..1781`) are 554 baze în gap-uri terminale (532 om 3′, 22 șoarece 5′), dar una co-optimă se oprește la `1790/1775` (750 terminale). Prefer semiglobal când aliniez cap-coadă o secvență scurtă (CDS, exon, primer, read NGS) pe o referință mai lungă, fără a trunchia capetele (ca local) și fără a penaliza flancurile (ca global), sau la suprapuneri între contig-uri.